學號：B03902090　系級：資工三　姓名：邵楚荏

1. (1%)請問 softmax 適不適合作為本次作業的 output layer? 寫出你最後選擇的 output layer 並說明理由。

Softmax 的公式: $$\sigma(\mathbf{z})_j = \frac{e^{z_j}}{\sum_{k=1}^{K} e^{z_k}} \quad \text{for } j = 1, \ldots, K.$$ ，即是將向量中的每一個值取 exponential 之後再取 normalize，而因為是取了 exponential，所以 softmax 會特別注重於向量中"最大"的那一個值，而不是向量中"較大"的值的分布。我想在這次作業中，我們要做的是 multi-class "multi-label"的預測，一本書可能有很多個 tag，因此 softmax 可能比較不適合做這次作業的 output layer。

至於我在這次作業中最後選擇的 output layer 為"sigmoid"這個 activation function， $$S(x) = \frac{1}{1 + e^{-x}}.$$ (sigmoid)這個 function 剛好會將原本 range 比較大的一組數據，normalize 到 0~1 的區間，因此只要設定一個好的 threshold，就能將一組數據中大於此 threshold 的值取出，當作這本書所 predict 出來的 tag!!

2. (1%)請設計實驗驗證上述推論。

為了比較第一題中 sigmoid 或者 softmax 適不適合當作這次作業的 output layer，我將 model 中的最後一層的 activation function 分別使用了 sigmoid 和 softmax(其餘皆保持不變)，並且做了一些比較:

```
model.add(Dense(38,activation='sigmoid'))
```
(最後一層為 sigmoid)

```
model.add(Dense(38,activation='softmax'))
```
(最後一層為 softmax)

※Kaggle 上 f1_score 的比較:

b03902090_aynk	0.50453	10

(sigmoid : 0.50453)

Your Best Entry ↑
Your submission scored **0.23640**, which is not an improvement of your best score. Keep trying!

(softmax : 0.23640)

※將 testing data 的 output 做比較:

在這題中，我去觀察了 testing data 在 model 最後一層的 output，下圖其中一筆 testing data 經過 softmax layer 之後所得出來的 38 維 vector:

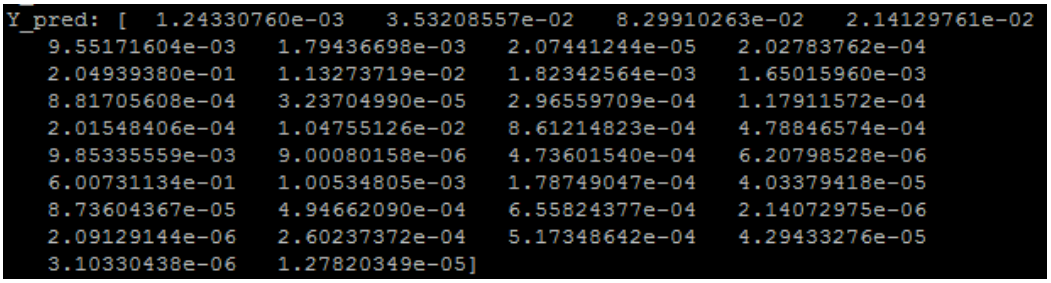

由上圖可以發現，38 維 vector 中的值都差得非常多，幾乎都是分布在 0.001 以下的值，唯有其中一維的值為 0.6007，所以 output 的 tag 就是這維所對應到的 tag，但在經過 softmax 之前，0.20493 這一維的 value 和 0.6007 的 value 是相近的，因為經過了 softmax，所以最後這兩維的值差距被放大，導致只會 output 出 0.6007 這個 tag(在 threshold 一樣為 0.3 的條件之下)。

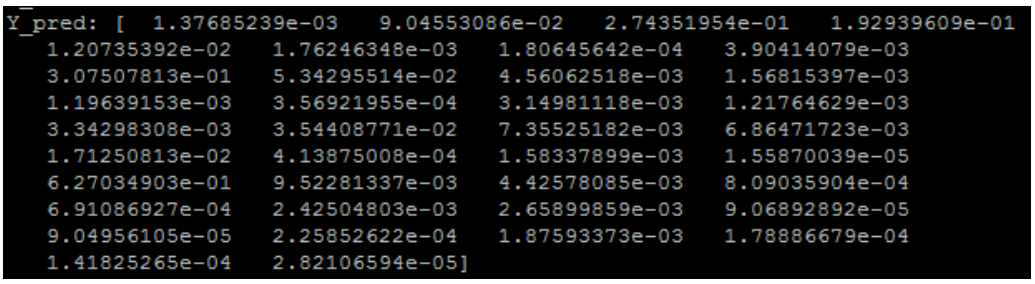

(同樣一筆 testing data 經過 sigmoid layer 之後所得的 38 維 vector)

由上圖可以發現，值的大小分布不在差距那麼大，而大於 0.1 的值就有 4 個，大於 0.3 的值也有兩個，也就是說，在用 sigmoid 的情況下，可能在 activation 前的相近的值，通過了 sigmoid 並不會被明顯放大!

由上述觀察中，更可以確定 sigmoid function 比 softmax function 更適合使用在 multi-class multi-label 的 task 之中!!

3. (1%)請試著分析 tags 的分布情況(數量)。

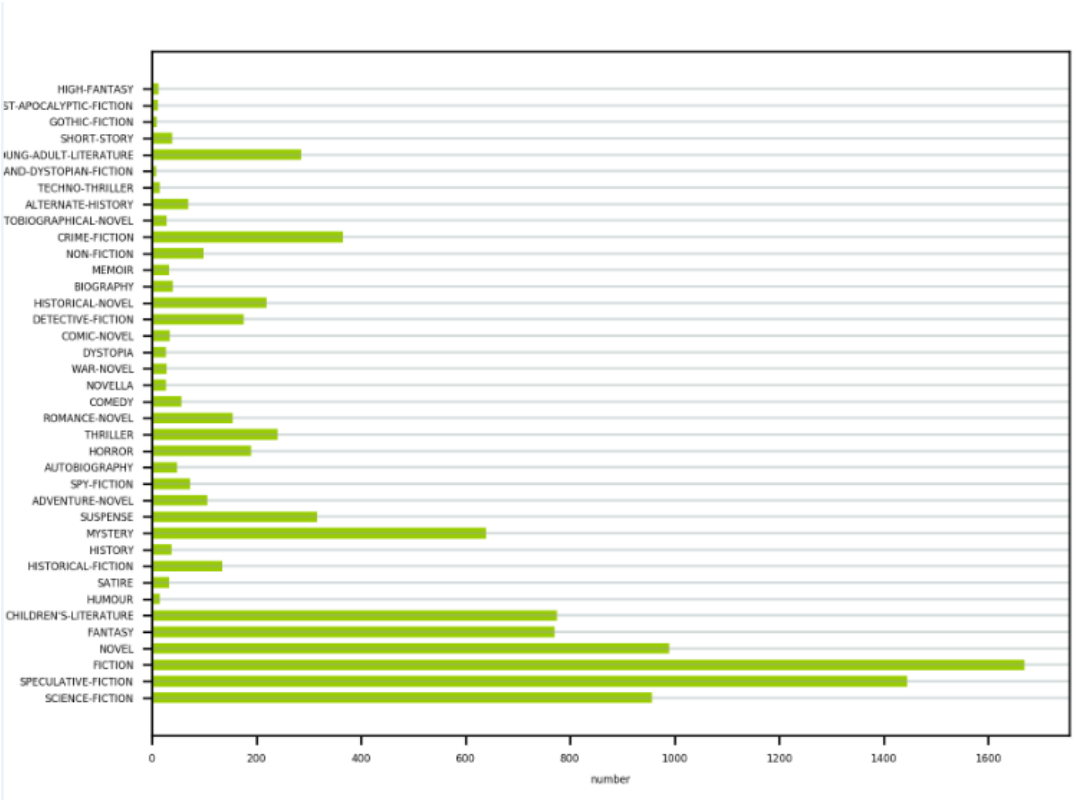

上圖為這次 training data 中所 label 出來的 tag 分布情況，其實可以發現，這次的 training data tag 分布相當的不平均，因此在 predict testing data 的時候可以發現 output 出來的 tag “Fiction”這個 tag 也佔了大多數，所以可以改進的方法可能是讓 training data 裡的 tag 分布平均一點，這樣訓練起來的效果也會好很多!

4. (1%)本次作業中使用何種方式得到 word embedding?請簡單描述做法。

最原本我是嘗試用 random 的 embedding matrix，在 train model 的過程中一起更新 matrix 裡的參數，但試了好幾種方法效果都不是太好，因此我最後用了 pre-trained 好的 word embedding，gensim 和 glove 我都分別試過了，最後是發現 glove42B 這份 corpus 的詞彙量比較多，比較不會出現找不到詞而變成零向量的情況，且 train 的效果也最好!

我的做法是，先將 glove42B.300.txt 這份檔案中的資料變成 dictionary，ex: dict[‘my’] = (out vector)，再利用 keras 中的 Tokenizer 找出 data 中的所有字彙量，利用這個 map 關係建立一個總字彙量的 embedding_matrix，維度為 (len(word), embedding_dim) !在 training 的時候，將　這個 pre-trained 好的 embedding_matrix feed 到 model 中第一層的 embedding layer!!

5. (1%)試比較 bag of word 和 RNN 何者在本次作業中效果較好。

```
### tokenizer for all data
tokenizer = Tokenizer()
tokenizer.fit_on_texts(all_corpus)
word_index = tokenizer.word_index
### convert word sequences to index sequence
print ('Convert to index sequences.')
train_sequences = tokenizer.texts_to_sequences(X_data)
test_sequences = tokenizer.texts_to_sequences(X_test)
print('sequences to matrix.')
train_bow = tokenizer.sequences_to_matrix(train_sequences, mode='freq')
test_bow = tokenizer.sequences_to_matrix(test_sequences, mode='freq')
```

(利用 Tokenizer 裡的 sequences_to_matrix 實作 bag of word)

```
model = Sequential()
model.add(Dense(768,input_shape = ((51867,)),activation='relu'))
model.add(BatchNormalization())
model.add(Dropout(0.5))
model.add(Dense(512,activation='relu'))
model.add(BatchNormalization())
model.add(Dropout(0.5))
model.add(Dense(256,activation='relu'))
model.add(BatchNormalization())
model.add(Dropout(0.5))
model.add(Dense(128,activation='relu'))
model.add(BatchNormalization())
model.add(Dropout(0.5))
model.add(Dense(38,activation='sigmoid'))
```

(將做完 bag of word 的 sequence 丟進 DNN 裡面作訓練)

這次用了 keras tokenizer 裡面的”sequence_to_matrix”這個 method 去實作 bag of word，另外 API 裡面 mode 參數設定為”freq”，將 sequence 分別變成 bag of word 的形式之後，丟進一個四層的 DNN 裡，去做 training，在 validation score 最後的結果大概是 0.49 左右，在 Kaggle 上的 f1 score 為 0.46810，比 RNN 的 performance 來的差一點。